

GIJO 제안자료 — 근거 없이는 답하지 않는 AI 데이터 HUB

GS텔레서비스 「AICC 지식 구조화 기반 AI 데이터 HUB 및 정합성 검증 PoC」 기술 제안 완전 온프레임 로컬 LLM 기반 근거답변 검증 PoC — 내부 검토용 초안 v0.7 (2026-08-10, 한국어 윤문 반영) 원본: 제안서 초안·제안요약 슬라이드 아티팩트(2026-08-08 작성, 2026-08-09 제품 문서 대조 갱신) △ 실적·핵심인력 경력·가격제안(밀봉)·별첨 요약서 4종은 **확정 후 제출본에서 별도 작성**

제안 개요	
사업기간	계약일로부터 12주
대상 업무	취소·반품·교환 SR 상담 (1개 브랜드 · 1개 상담조직)
구동 방식	발주사 내부 GPU · 완전 온프레임 — 데이터 외부 반출 0
환경	읽기 전용 격리 PoC (운영계 쓰기 없음 · 고객 직접 응대 없음)

1. 제안 요지 — 세 문장으로

이 PoC의 본질은 챗봇을 만드는 일이 아닙니다. AI가 믿고 쓸 수 있는 데이터를 만들고, 그 답이 옳음을 증명하는 일입니다.

원칙	뜻
① 근거가 곧 답변이다	모든 처리 안내에 출처 문서·구간·시행일·버전을 필수 필드로 붙입니다. 근거를 못 찾으면 그 답은 화면에 나가지 않습니다.
② 모르면 멈춘다	필수 정보 누락·기준 충돌·권한 밖 질문은 추정하지 않고 "무엇이 부족한지"를 밝히며 보류 합니다. "틀린 확답"보다 "정당한 보류"가 항상 이기는 정책이 중대오답 0건을 만듭니다.
③ 데이터는 집 밖에 안 나간다	답변·검증·검색·임베딩 전 모델이 발주사 GPU에 상주합니다. 학습배제를 계약으로 약속하는 게 아니라 통신 자체가 없어 원천 불가능 하게 만듭니다.

차별점 한 줄. 모델은 갈아끼우는 엔진입니다. 저희가 제안하는 것은 어떤 엔진을 꽂아도 근거 없이는 말 못 하게 만드는 차체입니다. 그래서 특정 모델이나 수행사에 묶이는 일이 구조적으로 생기지 않습니다.

이 골격은 제안용으로 그린 그림이 아닙니다. 자사 온프레임 AI 보안관제 제품에서 매일 운영하며 자동 회귀로 검증하고 있는 아키텍처입니다(실전 152상황을 매일 밤 다시 재고, 최근 회차는 151/152. 2026-08-10 기준). 본 PoC는 그 검증된 골격에 취소·반품·교환 업무 데이터를 엮는 작업입니다.

2. 합격선 (RFP 정량 목표)

지표	합격선
업무정확도 (비공개 300건)	90% 이상
근거일치 · 적정 보류	95% 이상
출처·버전 표시	100%
중대오답 · 보안사고	0건
최종응답 P95 (20 동시세션)	3.0초 이내
검색·확인시간	30% 단축

3. 아키텍처 — 5계층, 쉽게 보기

데이터는 위에서 아래로 흐릅니다. 오른쪽 기둥(감사로그·관측·평가 게이트)이 전 구간을 지켜봅니다.

① 원천 데이터 (발주사 시스템 · 읽기 전용)
고객 · 주문 · 결제·배송 · 클레임 · 상담사례 · 업무기준 문서
| 읽기 전용 수집 · 최소수집 · 가명처리
▼

② 데이터 정비·연결 (HUB)
품질 측정·정제 이력 | 식별자 연결·코드 매핑 | 시행일·버전 구조화
| 정비를 통과한 데이터만 색인
▼

③ 지식층 — 버전이 붙은 지식
업무기준 저장소(시행일·버전·승인자) | 업무규칙 온톨로지(예외·우선순위) | 하이브리드 색인(의미+키워드)
| 질문마다 "그 시점에 유효한 버전"만 검색
▼

④ 근거답변 엔진 — 전 모델 발주사 GPU 상주
검색·상태 조회 → 답변 생성(로컬 LLM) → ★근거 검증 게이트(문장↔근거 대조)
└─ 근거 확인됨 → 근거답변 + 출처·버전
└─ 부족·충돌 → 안전한 보류 + 사유
▼

⑤ 상담지원 화면 — AI 제안임을 명시
상황요약·처리방향 | 근거 원문·버전 원클릭 열람 | 피드백(채택/수정/보류) → 평가·개선 자료로 환류

[전 구간 감시 기둥] 감사로그(위변조 방지) · 성능 관측(P50/P95/P99 단계별) · 평가 게이트(회귀 통과 없이는 어떤 변경도 보

각 층을 쉽게 말하면:

- ① **원천**: 발주사 시스템을 읽기만 하는 통로로 연결합니다. PoC는 어떤 경우에도 운영계에 쓰지 않습니다.
- ② **정비**: AI가 쓰기 전에 데이터를 장부처럼 정리합니다. 빠진 값과 중복, 코드 불일치를 재고 고객에서 주문, 클레임으로 이어 붙이고, 정책 문서마다 시행일과 버전, 예외를 담니다. 무엇을 어떻게 고쳤는지는 정제 이력에 전부 남습니다.
- ③ **지식층**: 질문이 오면 그 시점에 유효한 버전만 검색합니다. 과거 기준과 현재 기준이 섞이는 사고를 구조로 막는 층입니다.
- ④ **엔진(핵심 차별점)**: 모델이 답을 만들면 거기서 끝나지 않습니다. 답의 문장 하나하나를 검색된 근거와 맞춰 보는 검증 게이트를 거칩니다. 통과한 답만 출처·버전과 함께 나가고, 그렇지 못하면 보류 카드로 넘어갑니다.
- ⑤ **화면**: 질문과 요약, 처리방향, 근거, 보류사유가 한 화면에 있고 근거 원문은 클릭 한 번이면 열립니다. 상담사의 채택·수정·보류는 평가와 개선 자료로 되 돌아옵니다.

4. 왜 로컬 LLM인가 — 세 가지 이유

1. **학습배제의 가장 강한 증빙(AQR-09)**: 외부 API를 쓰면 "재학습에 안 쓰겠다"는 계약과 증빙이 필요합니다. 로컬 구동은 데이터가 밖으로 나가는 통신 자체가 없습니다. 증빙은 망 구성도와 외부 발신 차단 로그면 끝납니다.
2. **비용 고정·종속 차단(AQR-10)**: 토큰당 과금이 없어 질의량이 늘어도 월 비용은 GPU 전기료 수준에 머뭙니다. 모델은 표준 파일(GGUF)이라 발주사가 직접 갈아 끼우고 다시 띄울 수 있습니다.
3. **3초를 우리가 통제(PER-01)**: 외부 API의 네트워크와 대기열 변동이 사라집니다. 지연이 생기는 구간이 전부 내부에 있어 단계별로 재고 통제할 수 있습니다.

모델은 못박지 않고 시험으로 뽑습니다 (RFP 4.8 개방성):

- G2(4주차)에 후보 2~3종(Qwen3-Next-80B, gpt-oss-120B 등 Apache 2.0 계열)을 동일 데이터·평가셋으로 **공개 비교**해 발주사와 채택 확정.
- 한국어 최상위 EXAONE은 **비상업 라이선스**라 기본 구성에서 배제하고 사유를 명시(라이선스 공개 원칙). 상업 이용이 자유로운 국산 경량 모델(카나나 등)은 보조 역할 후보로 병행 평가.
- 운영 전환 후에도 같은 절차 — GGUF 파일 교체 + 회귀 게이트 통과, 두 단계로 끝.

5. GPU 설계 — VRAM은 용량이 아니라 역할로 나눕니다

제안 구조는 GPU 2장을 나눠 쓰는 것입니다(총 96GB). "큰 GPU 하나에 다 넣기"는 하지 않습니다. 답을 만드는 무거운 일과 검증·검색처럼 가벼운 일을 물리적으로 갈라놓습니다. P95가 흔들리는 주원인이 자원 경합이기 때문입니다.

GPU	역할	배치
GPU A — 80GB급	"말하는 GPU" (직렬 대자원)	주력 답변 모델 80B 전문가 분업형(MoE) ≈55GB · 20 동시세션 대화 기억(KV 캐시) 12GB · 여유 13GB
GPU B — 16GB급	"검사하는 GPU" (병렬 소자원)	검증·요약 보조 8B ≈9GB · 임베딩(검색 눈) 2.5GB · 리랭커(재정렬기) 2.5GB · 여유 2GB

왜 이 구조인가: ① 답을 만드는 일과 검사하는 일이 GPU를 서로 뺏지 않습니다. 근거 대조를 생성과 나란히 돌려도 응답시간이 흔들리지 않습니다 ② 세션 캐시 12GB를 미리 떼어 두어 20 동시세션(PER-03)이 설계값입니다 ③ 남은 13GB는 G2에서 후보 모델을 갈아 끼워 시험하는 자리입니다.

규모별 가이드 — 발주사 장비가 바뀌어도 구조는 그대로, 모델 부품만 바꿉니다:

등급	VRAM	구성	솔직한 기대 수준
최소	24GB	32B급 4비트, 검증 검임 (직렬)	개발·시연용. 합격선(20세션+P95 3초)은 위험 — 동시 5~8세션 한계
기본	48GB	32B급 8비트 + 경량 보조	합격선 도전의 하한 . 복합·예외 시나리오에서 체급 한계 먼저 드러남
제안 ★	96~110GB	80B MoE + 8B 보조 병렬 검증	속도·품질·동시성의 균형점 — 3초와 20세션을 함께 노릴 수 있는 첫 구간. 발주사 보유 환경과 일치
확장	160GB+	235B급 또는 이중 A/B 상주	이득 완만 — PoC엔 과투자

자사 제품은 서버 GPU를 실측해 권장 등급을 자동으로 판정하고 안내하는 기능을 이미 갖고 있습니다. 장비가 확정되면 어느 구간인지 기계가 바로 판정합니다.

6. P95 3초 — 단계별 시간 예산으로 관리

"빨라졌다"가 아니라 어느 단계가 몇 초인지로 관리합니다. 요청 ID별 원시로그는 그대로 제출합니다 (사전 고정답변·실패질의 삭제 없음).

단계	예산	수단	담당
질문 이해·식별자 조회	0.2초	상태 조회는 정비된 HUB에서 — 원천 시스템 왕복 없음	GPU B + DB
하이브리드 검색 + 리랭킹	0.4초	벡터+키워드 병렬 · 유효 버전 사전 필터	GPU B
답변 생성	1.7초	근거 Top-k만 투입 + 구조 출력 + 스트리밍	GPU A
근거 검증	0.4초	생성 스트림과 병행 대조 — 직렬 대기 없음, 실패 시 즉시 보류	GPU B
여유 (P95 변동 흡수)	0.3초	20 동시세션 연속 배칭 지터 포함	—

- 1~2주차에 발주사 실 GPU에서 토큰 속도를 실측해 예산표를 실측치로 갱신합니다.
- 20 동시세션 부하시험은 G3(8주차) 전에 자체 수행해 여유를 수치로 확인합니다.

7. 운영 중인 우리 제품 ↔ 본 PoC — 1:1 대응

왼쪽은 전부 자사 온프레미 AI 플랫폼에서 지금 돌아가고 있는 실코드입니다. 새로 발명하는 것이 아니라 도메인을 바꿔 엮는 일임을 보여드립니다.

운영 중인 구성요소 (자사 제품)	본 PoC에서의 역할
로컬 LLM 프로세스 풀 — VRAM 예산·상주/교체·장애 자동 재기동	모델 4종 배치의 운용 엔진 (가용성 99.5%)
모델별 자동 적응 — 파일 메타를 읽어 구동 파라미터 자동 교정	후보 모델 교체 시험을 안전하게
하이브리드 검색 — 의미(벡터)+키워드 병행	지식층 검색 (조항 번호·코드 + 의미 동시)
온톨로지 지식망 — 6대 보안표준 약 2,000개 관계 운영	취소·반품·교환 규정의 예외·우선순위·충돌 구조화
문서 해시 버전 추적 — 1글자 변경도 재색인 강제	"문서는 고쳤는데 AI는 옛 기준" 사고 차단
이질 소스 정규화 허브 — 3종 소스 공통 스키마 상관	주문·결제·배송·클레임 커넥터의 골격 재사용
그라운드링 스택 + 무근거 감지 — 근거 없으면 보류 전환	근거 검증 게이트 (실측: 그라운드링 강화 > 모델 2배 확대)
3축 평가 게이트 + 매일 밤 자동 회귀(실전 152상황·최근 151/152)	모델·프롬프트·데이터 변경 통제, G2~G4 평가 대응
3중 방어 — 입구 가드레일 + 반입 문서 살균 + 출구 자격증명 가림, 자동 레드팀 상시	문서에 심어진 지시문이 AI를 조종하지 못하게 반입 단계 차단
개인정보 자동 마스킹 — 주민번호·카드번호는 AI 도달 전 가림	최소수집·가명처리의 내장 장치
거짓 완료 차단 관문 — 안 한 일을 "했다"고 답하면 출구에서 차단	중대오답 0건의 핵심 장치
감사로그 + 판정 이력 병기	위변조 방지 기록·답변 재현
승인 카드(결재판) — AI 제안·실행 분리, 원클릭 되돌리기	오인방지 + 채택·수정·보류 피드백 UI
지연 안내 전환 + 단계별 소요 계측	시간초과 안전 안내 + P50/P95/P99 관측
백업·복원 검증 — "복구된다"를 실제로 시험	산출물 인수·재현시험, 보안 종료 증빙
브루트포스 방어·역할권한·2차 인증(TOTP) 하드닝	PoC 계정의 최소권한·다중인증(폐쇄망 동작)

쉽게 말하면, 이 RFP가 요구하는 시스템의 축소판을 이미 다른 업종에서 매일 돌리고 있습니다. 그래서 12주를 엔진 개발이 아니라 데이터와 업무를 이해하는 데 쓸 수 있습니다.

8. 정량 목표 — 지표마다 책임지는 부품이 있습니다

지표	합격선	책임 부품 · 달성 방법
업무정확도	90%↑	그라운드링(근거 묶기) + 업무규칙 온톨로지(예외·우선순위를 모델 재량이 아닌 규칙으로) + 모범 사례 예시
근거일치	95%↑	보조 모델의 문장 단위 근거 대조 — 근거 없는 문장은 화면 표시 전 차단

지표	합격선	책임 부품 · 달성 방법
출처·버전 표시	100%	출처·시행일·버전 = 필수 필드 — 누락 시 답변 조립 자체가 불가
정답 근거 Top-5	90%↑	하이브리드 검색 + 리랭커 정밀 재정렬
중대오답	0건	금전·약정 판단은 보류 우선 + 거짓 완료 차단 관문(실제 데이터와 대조해 출구 차단 — 운영 중 기능)
적정 보류	95%↑	필수항목 체크 + 기준 충돌 감지 + 보류 사유 명시
P95 응답	3.0초	2-GPU 분리 + 단계별 예산 + 생성·검증 병행
검색·확인시간	30%↓	한 화면 통합 UI — 탐색 시간 자체를 제거, 그림자 운영 중앙값 측정

요구사항 1:1 대응 판정 요약 (61항목):

판정	수	뜻
충족	44	제품 보유 기능·구조
수행	14	방법론 보유, PoC 기간 수행
조건부	3	실측으로 확정 — AQR-03(비열위 95%) · PER-01(P95 3초) · PER-03(20세션)
미충족	0	—

RFP 4장 원칙("가능·지원 예정·협의 필요 표현 금지")에 따라, 실측 없이 확정할 수 없는 3건은 정직하게 조건부로 표기하고 확정 시점(G1~G3)을 명시했습니다.

9. 보안·개인정보 — 폐쇄형 구동의 이점

- **격리(SEC-01):** PoC 전용 계정·망·저장소, 운영계는 읽기 전용 톨로만. 외부 통신 전면 차단(에어갭) 모드를 제품 기능으로 보유 — 차단 이력까지 기록.
- **학습배제(AQR-09):** 로컬 구동 — 모델 제공자에게 전송되는 데이터가 존재하지 않음. 증빙은 망 구성도 + 차단 로그.
- **최소권한(SEC-02):** 역할 기반 접근 + 폐쇄망에서 동작하는 2차 인증(TOTP) + 세션 통제.
- **암호화(SEC-03):** 저장 AES-256(선택형) — 키는 발주사 서버에서 생성·보관, 공급사는 모름 + 전송 암호화.
- **개인정보(SEC-04):** 주민번호·카드번호는 AI에 닿기 전 자동 마스킹, 가린 사실 기록 — 내장 기능.
- **로그(SEC-05):** 위변조 방지 기록 — 끌 수 없음, 기본 3년 보관, 정리 사실도 기록. 동일 입력·동일 버전 재현 지원.
- **공격방어(SEC-06) — 3중 방어:** ① 입구 가드레일 ② 반입 문서 살균(문서 속 숨은 지시문 무력화) ③ 출구 자격증명 가림 + 자동 레드팀 상시 회귀.
- **종료(SEC-08):** 데이터·로그·백업·모델 캐시 완전삭제 + 확인서. 삭제 전 "복구되는 백업인지" 검증 절차 보유.

10. 12주 수행 일정 — 실작업·협조·달력 시간을 갈라서 관리

주차	관문	🟢 제안사 실작업	👉 발주사 협조 (요청 기한)
1~2주	G1 데이터 준비	원천 조사·품질 측정 가동, 실 GPU 속도 실측 — 실작업 ~3일	계정·망 접근(착수+3일) · 데이터 제공 승인(+7일) · 업무담당자 배정(+10일)
3~4주	G2 기준·평가설계	용어·코드 매핑, 평가셋 100건 초안, 모델 공개 비교 — ~4일	업무전문가 2인 정답 검토·승인
5~8주	G3 기능·보안 준비	구현 전체(커넥터·지식층·화면·레드팀·부하시험) — 당사 최단 구간	중간점검 참석
9~10주	G4 비공개 평가	오류분석·수정·회귀 — 반복 2~3회전	비공개 300건 평가는 발주사 주관
11주	G5 그림자 운영	관찰·즉시 수정	상담사 편성(10주차까지 확정)
12주	G6 최종 인수	산출물 정리·재현시험·교육·보안 삭제 확인서	인수 확인·교육 참석

발주사 협조 캘린더(착수계획서에 명문화): 기한이 지나면 해당 관문 일정은 지난 날수만큼 뒤로 밀리 범위와 검증 기준은 그대로 둡니다. "기다리겠다"가 아니라 "챙겨드리겠습니다"는 협업 표입니다. 당사 실작업이 짧은 만큼 남는 시간은 같은 12주 안에서 검증을 2~3회전 더 돌리고 시연을 준비하는 데 씁니다.

11. 위험을 숨기지 않습니다 — 조건부 3건의 관리 계획

위험	내용	통제
AQR-03 비열위 95%	로컬 오픈 모델은 최상위 상용 모델과 맨몸 격차가 있음. 전략은 격차를 데이터로 메우는 것 — 정비 데이터·온톨로지·근거 게이트가 붙은 로컬 구성 대(對) 맨몸 기준모델 비교(자사 실측: 그라운드링 강화 > 모델 2배 확대)	G2(4주차) 조기 비교 자청 · 미달 시 승인 상용모델 대체경로 이중화(근거·보류·감사 골격은 동일 유지)
PER-01·03 성능	3초·20세션은 GPU 기종·장수에 따라 달라지는 실측 값	1~2주차 실 GPU 실측 → 예산표 갱신 · 미달 시 양자화·모델 크기 조정(전부 회귀 게이트 통과 조건) · G3 전 자체 부하시험
데이터 품질 의존	정확도 90%는 원천 데이터가 받쳐줘야 함 — 핵심 결손은 어떤 모델도 못 메움	G1 관문에서 결손을 숫자로 보고 — 추정으로 메우지 않고 대체안 또는 범위 조정을 서면 제안. 커머스 커넥터는 신규 개발이나 정규화 허브 골격 재사용으로 파서 계층에 국한

12. 산출물·개방성 약속 — 발주사가 직접 굴릴 수 있는 상태로

- 데이터·규칙·평가셋: **CSV / JSON / SQL** — 원본 구조·의미 유지, 발주사 저장소에 이력 포함 제출
- 소스코드·설정·프롬프트: 버전 이력 + 빌드·재현 절차 — **제출물만으로 핵심 평가 재현 가능**을 인수 조건으로 수용
- 모델: **GGUF 표준 파일** + 정확한 출처·버전·라이선스 명세 — 발주사가 직접 교체·재구동 가능
- 전 구성요소의 이름·버전·라이선스·지원종료일 공개 — 비상업 라이선스 모델은 기본 구성에서 배제
- 종료 시 데이터·로그·백업·모델 캐시 **완전삭제 + 확인서**
- 발주사 데이터를 당사 모델 학습·벤치마크·홍보에 사용하지 않음 — 로컬 구동이라 기술적으로도 불가능

맺음 한 줄. 상담사가 3초 안에 "된다/안 된다 + 왜 + 어느 규정 몇 판"을 받고 시가 모르면 모른다고 말하는 시스템입니다. 그 증명을 12주 안에 발주사 장비 안에서 끝내겠습니다.

부록. 용어 풀이 — 쉬운 말로

용어	쉬운 풀이
로컬 LLM	외부 서비스가 아니라 회사 안 GPU에서 직접 돌리는 AI 모델 — 데이터가 밖으로 안 나감
전문가 분업형(MoE)	큰 두뇌를 여러 전문가로 쪼개 질문마다 필요한 전문가만 깨우는 방식 — 큰 지식 + 빠른 속도
양자화(4/8비트 압축)	모델 무게를 압축해 GPU 메모리를 아끼는 기술 — 숫자가 작을수록 가볍지만 미세하게 덜 정밀
GGUF	누구나 쓰는 표준 형식의 AI 모델 파일 — 특정 회사 전용이 아니라 직접 교체 가능
세션 캐시(대화 기억)	동시 접속자마다 대화 앞부분을 GPU에 기억해 두는 메모장 — 접속자 수만큼 자리 필요
임베딩(검색 눈)	문서와 질문을 "의미 좌표"로 바꿔 비슷한 규정을 찾게 하는 부품
리랭커(재정렬기)	검색이 찾아온 후보들을 "진짜 근거 순"으로 다시 줄 세우는 정밀 심사관
하이브리드 검색(겉검색)	의미로 찾는 검색과 정확한 단어·코드로 찾는 검색을 동시에 쓰는 방식
그라운딩(근거 묶기)	AI가 제공된 자료 밖의 내용을 지어내지 못하게 근거에 묶어 두는 기법
온톨로지(규정 관계망)	규정·예외·우선순위를 그물처럼 연결해 둔 지식 관계망 — AI 재량이 아닌 규칙으로 판단
P95	요청 100건 중 95번째로 느린 응답의 시간 — "대부분의 사용자가 겪는 최악값"
KV 캐시	대화 앞부분 계산 결과를 GPU에 저장해 재계산을 피하는 메모리

본 문서는 제안 검토용 초안입니다. RFP 문의처: 이기열 팀장(AX추진팀) · 제안서 규격: A4 세로 · 맑은 고딕 · DOCX+PDF
원본 아티팩트: 제안서 초안(claude.ai/code/artifact/9050b56a...) · 제안요약 슬라이드(3fe08b05...)