

GIJO AS — 제품 소개 자료 (v1.0.0)

한 명의 보안담당자가 여러 명 몫을 해내도록.

쏟아지는 보안 정보를 AI 에이전트가 **자동으로 엮어** 처리하는 온프레미스 보안 운영 플랫폼.

*본 자료의 모든 수치·예시·스크린샷은 v1.0.0을 실제 구동해 뽑은 **실측 백데이터**입니다(서버 자동화 테스트 245개 통과).*

*스크린샷은 실제 제품 화면(HTML/CSS)을 실측 서버 응답으로 렌더링한 것입니다 — 목업이 아닙니다.
(`screenshots/` 폴더)*

1. 왜 필요한가 — 보안담당자의 현실

기업 보안담당자는 **항상 인원이 부족**한데, 처리해야 할 일과 받는 정보는 계속 늘어납니다.

현실의 고충	무엇이 힘든가
보안제품 운영·관리	패치·메뉴 확인·장애 대응·발견 문제 전달을 사람이 일일이 추적
쏟아지는 보안 정보	제품 로그, CTI(위협 인텔), 취약점 스캔 결과가 따로따로 도착
정보 간 대조가 수작업	"이 위협이 우리 어느 자산에?", "이 자산 문제가 어느 서비스에?"를 눈으로 매칭
반복되는 보고	임원·팀장 보고서, KPI를 매번 손으로 취합
AI 보안까지 추가	이제 AI 모델 자산·공급망까지 관리 대상

핵심 문제: 개별 데이터는 있는데 **서로 연결이 안 되어**, 담당자가 그 연결을 머리로 대신하고 있음.

2. GIJO AS 한 줄 정의

보안 특화 Agent AI 팀 + 로컬 LLM이 담당자의 업무를 대신 수행하고,
흩어진 보안 정보를 자동으로 **상관(correlate)**시켜 "지금 무엇이 위험한지"를 바로 보여줍니다.
모든 데이터·AI가 **폐쇄망(온프레미스)** 안에서만 돕니다 — 데이터가 외부로 나가지 않습니다.

3. 핵심 가치 3가지

① 자동 상관관계 — "정보를 엮어주는" 레이어

개별 사일로(자산·CTI·점검·컴플라이언스)를 자동으로 연결합니다.

CTI 위협 → 영향받는 내부 자산 → 영향받는 업무 서비스
스캔 취약점 → 승인 검토 → SBOM 반영

② 온프레미스 Agent AI — 데이터 주권

8종 보안 에이전트가 로컬 GPU의 LLM으로 작동. 외부 API·클라우드 없이 폐쇄망 완결.

③ 지속 학습 거버넌스 — 쓸수록 똑똑해짐

RAG(장기 기억) + 헤르메스 폐쇄형 학습 루프로 실제 대화를 학습에 반영. 점검·승인은 감사 추적으로 관리.

4. 주요 기능 (업무 중심)

4.1 🛡️ 에이전트 AI 팀 + 복합 지시

목적: 자연어로 지시하면 보안 에이전트 팀이 알아서 협업 처리.

8종 고정 에이전트(실측):

에이전트	역할	추천 로컬 LLM
오케스트레이터	작업 분배·결과 취합	Qwen2.5 7B
스캔	정적분석 실행 (ModelScan)	Foundation-Sec 8B
침투테스트	익스플로잇 검증	Lily Cybersecurity 7B
분석	우선순위 판단·설명	Qwen2.5 7B
SBOM	SBOM 생성·정리	ZySec 7B
CTI	딥웹·다크웹 감시	Foundation-Sec 8B
리포트	내부 보고서 작성	Qwen2.5 7B
모델 진화	보안 특화 LLM 학습	Hermes 3

복합 지시(오케스트레이션): 여러 작업을 한 문장으로.

실측 — 지시: **"CTI 영향 자산 스캔하고 리포트까지"**
→ 자동 계획: ① **스캔(대상=CTI 영향 자산 자동 해석)** → ② **리포트 작성** (2단계 복합 실행)

각 단계는 협업 로그에 실시간 표시되고, 스캔 결과가 리포트로 이어집니다.

AI 팀

● 에이전트 AI

모니터링

◆ 대시보드

📊 보안 KPI

◇ AI 자산

□ AI-BOM

△ 위협 인텔리전스

🔍 취약 자산관리

거버넌스

✓ 컴플라이언스

📄 내부 리포트

◆ 승인 워크플로우

🔧 운영 가이드

고급 기능

○ 보안 LLM 합성

📡 헤르메스 학습 루프

🔊 AI 기억 · 학습

\$ 사용량 · 요금

시스템

📄 로그

📄 모니터링

에이전트 AI

여러 보안 특화 LLM 에이전트가 역할을 나눠 협업하고, 작업을 지시하면 팀이 알아서 처리합니다

에이전트 설정

+ 에이전트 추가

예: fraud-detect-llm 취약점 전체 재스캔하고 우선순위 정리해서 리포트까지 작성해줘

▶ 에이전트 팀에게 지시하기

전체 에이전트

8

오늘 생성된 작업

0

지금 작업 중

0

완료된 작업

0

우리 팀 — 보안 에이전트 로스터

각 에이전트는 역할에 맞는 전용 모델을 사용하며, 오케스트레이터가 작업을 나누고 결과를 취합합니다

◆ 오케스트레이터 ● 모니터링
작업 분배 · 결과 취합

전역 모델 따름

🔥 추천: Qwen2.5 7B Instruct 약 4.7GB

받기

지시 이해와 한국어 라우팅 정확도가 좋아 작업 분배 의도 판단에 적합. 더 빠른 응답이 급하면 Llama 3.2 3B로 교체하세요.

📄 스캔 에이전트 ● 대기중
정적분석 실행 (ModelScan)

전역 모델 따름

🔥 추천: Foundation-Sec 8B 약 4.9GB

받기

스캔(ModelScan) 결과로 나온 모델 취약점을 위협 관점에서 해석·요약하는 데 강합니다.

🔍 침투테스트 에이전트 ● 대기중
익스플로잇 검증 (Penlilent)

전역 모델 따름

🔥 추천: Lily Cybersecurity 7B 약 4.4GB

받기

공격 기법·익스플로잇·사고대응에 특화된 보안 모델(GUO 기본). 침투테스트 검증 설명에 적합.

🔍 분석 에이전트 ● 대기중
우선순위 판단 · 설명

전역 모델 따름

🔥 추천: Qwen2.5 7B Instruct 약 4.7GB

받기

우선순위 판단과 매끄러운 한국어 설명 품질이 좋습니다. 학습 데이터셋 Q&A 생성에도 이 에이전트가 쓰입니다.

📄 SBOM 에이전트 ● 대기중
SBOM 생성 · 정리

전역 모델 따름

🔥 추천: ZycSec 7B (SecurityLLM) 약 4.4GB

받기

보안 정책·컴플라이언스·구성 문서 이해에 강해 SBOM 항목 정리·설명에 맞습니다.

🔍 CTI 에이전트 ● 모니터링
딥웹 · 다크웹 감지

전역 모델 따름

🔥 추천: Foundation-Sec 8B 약 4.9GB

받기

딥웹·다크웹 위협 인텔리전스를 분석·추론하는 범용 보안 파운데이션 모델(Cisco).

📄 리포트 에이전트 ● 대기중
내부 보고서 작성

전역 모델 따름

🔥 추천: Qwen2.5 7B Instruct 약 4.7GB

받기

한국어 보고서 문제·서식 품질이 가장 좋아 내부 보고서 작성에 적합합니다.

🔍 모델 진화 에이전트 ● 대기중
보안 특화 LLM 병합

전역 모델 따름

🔥 추천: Hermes 3 (Llama 3.1 8B) 약 4.9GB

받기

헤르메스 학습 루프의 최적 배이스 — 지시파라미터 구조화 중력이 뛰어나 모델 진화(학습) 대상에 맞습니다.

터미널 — 협업 · LLM 실행작 로그

에이전트 협업 이벤트와 로컬 LLM 실행작(추론·임베딩·모델 로드/스왑)을 시간순으로 스트리밍합니다. 각 추론의 모델 토큰 생성 속도(tok/s)는 llama.cpp 실측치입니다. llama-server 자체 stdout/stderr는 좌측 "로그" 메뉴에서 확인할 수 있습니다.

이벤트 없음

에이전트별 브레인 모델

등록된 에이전트가 실제로 참조하는 모델 ID 목록

모든 에이전트가 전역 모델을 공유합니다

AI 엔진 상태

llama-server

중지됨

HuggingFace 모델 검색 · 불러오기 ? 도움

보안 특화 오픈소스 모델을 검색해 로컬로 내려받습니다. 뭘 받아야 할지 모르겠다면 ? 도움(추천 LLM 가이드)에서 용도별 추천 모델을 확인하세요.

예: cybersecurity, WhiteRabbitNeo, Foundation-Sec

검색

검색어를 입력하고 검색 버튼을 눌러주세요.

실시간 협업 현황

에이전트 간 작업 위임 · 🔴 로컬 LLM 추론 실행 (WebSocket 실시간 수신 — 모델 토큰·생성속도 실측)

아직 협업 이벤트가 없습니다 — 지시를 내리면 여기에 실시간으로 표시됩니다

지우기

AI 팀

에이전트 AI

모니터링

대시보드

보안 KPI

AI 자산

AI-BOM

위협 인텔리전스

취약 자산관리

거버넌스

컴플라이언스

내부 리포트

승인 워크플로우

운영 가이드

고급 기능

보안 LLM 합성

헤르메스 학습 루프

추천 LLM 가이드

AI 기어 · 학습

사용량 · 요금

시스템

로그

설정

추천 LLM 가이드

GUIO AS에서 쓰기 좋은 로컬 LLM을 용도별로 정리했습니다. 설명을 보고 다운로드를 누르면 로컬에 받아지고, 에이전트 카드의 모델 드롭다운에서 선택할 수 있습니다.

- 모두 **GGUF** 형식이라 로컬(lama.cpp)에서 바로 돌린다. 다운로드는 **Q4_K_M** 양자화본 한 개만 받습니다(용량 절감).
- 7-8B는 약 **4-5GB**라 몇 분 걸릴 수 있어요. 진행 상황은 좌측 **로그** 메뉴에서 실시간으로 볼 수 있습니다.
- 여러 모델을 받아두면 에이전트마다 다른 모델을 배경화 **동시에** 굴릴 수 있습니다(VRAM 여유 안에서 자동 관리).
- 카드의 **추천 에이전트** 배치는 그 모델이 어느 AI 팀 에이전트에 잘 맞는지 표시합니다 — **에이전트 AI** 화면에서 카드마다 바로 [받기][적용]도 할 수 있어요.

보안 특화 LLM

침해사고 대응·취약점 분석·보안 개념을 이미 학습한 모델. 보안 담당 에이전트의 두뇌로 바로 쓰기 좋습니다.

Lily Cybersecurity 7B **7B** **GUIO 기본**
사이버보안 일반 Q&A 사고대응 개념 설명에 특화. GUIO AS의 확장 채팅 모델입니다.

추천 에이전트 **침투테스트 에이전트**

QuantFactory/Lily-Cybersecurity-7B-v8.2-GGUF

약 4.4GB

다운로드

ZySec 7B (SecurityLLM) **7B**
보안 운영정책 컴플라이언스 문서 이해에 강합니다. 리포트/거버넌스 계열 에이전트에 적합.

추천 에이전트 **SBOM 에이전트**

QuantFactory/SecurityLLM-GGUF

약 4.4GB

다운로드

Foundation-Sec 8B **8B** **Cisco**
위협 분석·보안 전문용 파운데이션 모델(Cisco Foundation AI). 분석·CTI 에이전트 후보.

추천 에이전트 **스캔 에이전트** **CTI 에이전트**

mrademacher/Foundation-Sec-8B-GGUF

약 4.9GB

다운로드

파인튜닝 베이스 LLM

우리 문서로 학습(파인튜닝)시켜 문제·판단을 각인시킬 때 쓰는 범용 베이스. 학습이 잘 먹고 자료가 많은 모델을 골랐습니다.

Hermes 3 (Llama 3.1 8B) **8B**
학습루프 베이스

헤르메스 학습 루프의 확장 베이스. 지시 따르기·구조화·출력기 뛰어난 자가학습 루프에 적합합니다. 실제 학습은 HF 일본(NousResearch/Hermes-3-Llama-3.1-8B)으로, 이 GGUF는 학습 전 베이스 용답 확인용.

추천 에이전트 **모델 진화 에이전트**

NousResearch/Hermes-3-Llama-3.1-8B-GGUF

약 4.9GB

다운로드

Llama 3.1 8B Instruct **8B**

가장 널리 쓰이는 파인튜닝 베이스. 한국어 포함 다국

어와 도구 사용이 안정적입니다.

bartowski/Meta-Llama-3.1-8B-Instruct-GGUF

약 4.9GB

다운로드

Qwen2.5 7B Instruct **7B**

지시 따르기·한국어 품질이 좋아 파인튜닝 후 실무 응

답이 매끄럽습니다.

추천 에이전트 **오케스트레이터** **분석 에이전트**

리포트 에이전트

bartowski/Qwen2.5-7B-Instruct-GGUF

약 4.7GB

다운로드

Phi-3.5 mini **3.8B** **경량 베이스**

작지만 추론이 좋아 GPU 여유가 적을 때 파인튜닝 베이스로 쓰기 좋습니다.

bartowski/Phi-3.5-mini-Instruct-GGUF

약 2.4GB

다운로드

지식 관리(RAG)에 강한 LLM

장기 기억(문서 검색) 결과를 잘 활용하려면 긴 컨텍스트와 요약력이 필요합니다. 검색용 임베딩 모델도 여기 있습니다.

Qwen2.5 14B Instruct **14B** **롱컨텍스트**

128K 토큰 컨텍스트. 많은 문서를 넣고 근거 기반으로 답하게 할 때 강합니다(VRAM 넉넉할 때).

bartowski/Qwen2.5-14B-Instruct-GGUF

약 9GB

다운로드

Qwen2.5 7B Instruct **7B** **롱컨텍스트**

128K 컨텍스트를 가벼운 비용으로. 일상적인 RAG 응

답에 균형이 좋습니다.

추천 에이전트 **오케스트레이터** **분석 에이전트**

리포트 에이전트

bartowski/Qwen2.5-7B-Instruct-GGUF

약 4.7GB

다운로드

BGE-M3 (임베딩) **임베딩** **임베딩**

장기 기억 검색에 쓰는 임베딩 모델. GUIO에 기본 내장

돼 있으며, 교체·재배치용으로 받을 수 있습니다.

gpustack/bge-m3-GGUF

약 0.4GB

다운로드

가벼운 LLM

빠른 응답·저사양 여러 모델 동시 상주가 필요할 때. 분류·라우팅 같은 가벼운 작업에 딱 맞습니다.

Llama 3.2 3B **3B**

작은 크기에 품질이 좋아 빠른 응답용으로 인기. 여러

개를 동시에 돌리기 좋습니다.

bartowski/Llama-3.2-3B-Instruct-GGUF

약 2GB

다운로드

Qwen2.5 3B **3B**

한국어가 준수한 경량 모델. 요약·분류 같은 보조 작업

에 적합합니다.

bartowski/Qwen2.5-3B-Instruct-GGUF

약 2GB

다운로드

Llama 3.2 1B **1B**

초경량. 의도 분류·라우팅처럼 아주 빠른 판단이 필요

한 곳에.

bartowski/Llama-3.2-1B-Instruct-GGUF

약 0.8GB

다운로드

Qwen2 0.5B **0.5B** **초경량**

가장 가벼운 테스트·개발용. 파이썬이나 점점이나 저사

양 데모에 씁니다.

Qwen/Qwen2-0.5B-Instruct-GGUF

약 0.4GB

다운로드

4.2 🎯 CTI ↔ 내부 자산 자동 매칭 *(핵심 차별점)*


목적: "이 위협이 우리 어느 자산에 영향?"을 자동으로.

CTI 위협의 대상 텍스트를 자산의 구체적 식별자(컴포넌트·CVE·모델명)와 대조합니다.

실측 — 수집 위협 5건 중 4건이 자산에 매칭, 영향 자산 3곳:

위협 (target)	심각도	→ 영향 자산	매칭 근거
Qwen2.5 오픈웨이트 모델 가중치 변조 공급망 위협	주의	사내 보안 상담 챗봇	qwen2
bge-m3 임베딩 배포 패키지 악성코드 삽입	긴급	사내 보안 상담 챗봇	bge
KoBERT 분류 모델 대상 프롬프트 인젝션 캠페인	주의	문서 민감도 분류 AI	kobert
IsolationForest 이상탐지 우회 PoC 공개	정보	이상행위 탐지 엔진	isolationforest
(다크웹 계정 유출 — 무관)	정보	*(매칭 없음, 정상 제외)*	—

담당자의 눈 대조 작업을 없앴. 무관한 위협은 오탐 없이 걸러냄.



4.3 서비스 영향도 — 자산 → 업무 서비스

목적: "이 자산/보안제품 문제가 어느 업무 서비스에 영향?"을 자동으로.

자산을 업무 서비스로 묶어 위험(자산 취약점·CTI 위협·지연 점검)을 롤업합니다.

실측 — 서비스 3곳 모두 CTI 위협으로 "영향도 높음":

서비스	자산	영향도	위험 요인
임직원 보안 포털	사내 보안 상담 챗봇	높음	CTI 위협 1
문서관리 시스템	문서 민감도 분류 AI	높음	CTI 위협 1
SOC 관제 플랫폼	이상행위 탐지 엔진	높음	CTI 위협 1

위협 → 자산 → 서비스까지 한 번에 연결. "지금 위험한 서비스"를 임원에게 바로 설명.

AI 팀

● 에이전트 AI

모니터링

◆ 대시보드

■ 보안 KPI

◇ AI 자산

□ AI-BOM

△ 위협 인텔리전스

⑦ 취약 자산관리

거버넌스

✓ 컴플라이언스

■ 내부 리포트

◆ 승인 워크플로우

⚙ 운영 가이드

고급 기능

○ 보안 LLM 합성

■ 헤르메스 학습 루프

● AI 기억 · 학습

\$ 사용량 · 요금

시스템

☰ 로그

⚙ 설정

GIJO GIJO AS 2026. 07. 16. 오후 03:29

● 운영중 LIVE

CSV 내보내기

탐지 결과 가져오기

+ 자산 등록

AI 자산

코드 저장소 자동 스캔 · 외부 탐지 결과 업로드 · 수동 등록으로 전사 AI 자산을 전수 파악 · 총 3건

코드 저장소 스캔 온프레미스 · 자체 탐지

GitHub 조직/사용자의 저장소를 풀어 AI 라이브러리(openai langchain transformers 등) 의존성이 있는 repo를 개발할 AI 자산으로 자동 등록합니다. 토큰은 저장하지 않고 이 스캔에만 사용합니다. 온프레미스 GitHub Enterprise는 Base URL로 지정하세요.

조직 또는 사용자명 (예: my-company)

엑세스 토큰 (선택 — 없으면 rate limit 낮음)

Base URL (선택 — GitHub Enterprise)

스캔

전체 자산 3

고위험 0

중위험 0

저위험 3

SBOM 미생성 3

서비스 현황도 자산 → 업무 서비스 의존성

각 자산이 지원하는 서비스별로 위험(고위험 자산 CTI 위험 지면 점함)을 모아 "지금 위험한 서비스"를 보여줍니다. 자산 등록 시 지원 서비스를 지정하면 집계됩니다.

영향도 높음 임직원 보안 챗봇 자산 1 · 사내 보안 상담 챗봇 CTI 위험 1

영향도 높음 문서관리 시스템 자산 1 · 문서 민감도 분류 AI CTI 위험 1

영향도 높음 SOC 관제 플랫폼 자산 1 · 이상행위 탐지 엔진 CTI 위험 1

모형명, 소유부서로 검색

전체 고위험 SBOM 미생성 미스캔 최근 등록

자산명	유형	소유부서	위험도	최근 스캔	SBOM
사내 보안 상담 챗봇 /srv/ai/secbot	LLM 서비스	보안팀	● 미스캔	-	생성하기 재스캔 →
문서 민감도 분류 AI /srv/ai/doc-classifier	분류 모델	정보보호팀	● 미스캔	-	생성하기 재스캔 →
이상행위 탐지 엔진 /srv/ai/anomaly	이상탐지 모델	SOC	● 미스캔	-	생성하기 재스캔 →

전체 3건 중 3건 표시


GIJO

© 2026 GIJO Technology · GIJO AS Platform · Confidential

4.4 📦 자산 인벤토리 · AI-BOM · SBOM

목적: AI 자산뿐 아니라 받는 다양한 정보를 구성명세로 관리하고 취약점을 빠르게 확인.


- **자산 인벤토리:** AI 자산 + 일반 IT 자산(Nessus 업로드), 컴포넌트·소유부서·지원 서비스
- **AI-BOM:** 모델·데이터·프롬프트·도구·인프라 5영역 명세
- **SBOM 내보내기:** CycloneDX 및 SPDX-2.3 표준 지원



4.5 취약점 승인 워크플로우 (거버넌스)

목적: 스캔 finding을 검토해 확정/오탐 처리 → SBOM 반영 게이트.

담당자가 finding을 **승인(확정)** 또는 **반려(오탐)** 처리. 반려된 오탐은 SBOM 취약점에서 자동 제외.
finding 내용 해시로 상태를 저장해 **재스캔 후에도 검토 결과 유지**.



4.6 ✂ 보안제품 운영 가이드 (유지보수 거버넌스)

목적: 패치·메뉴 확인·장애 대응을 일정→보고→승인 거버넌스로.

- 지식베이스: 매뉴얼·에러로그(.log) 업로드 → RAG 검색으로 메뉴 확인·장애처리
- 점검 거버넌스: 일정 등록 → 결과 보고 → 관리자 승인/반려 (반복주기 자동 생성)
- 이력 타임라인 + 이메일 알림: 지연 점검을 담당자에게 자동 통지

실측 — 점검 6건(전 상태 시연):

점검	대상	상태
방화벽 정책 정기 점검	경계 방화벽(FW-01)	예정(오늘 마감)
프롬프트 가드레일 점검	보안 상담 챗봇	승인 대기
학습데이터 접근권한 점검	문서 민감도 분류 AI	승인됨
오탐 룰 점검	이상행위 탐지 엔진	반려
WAF 룰셋 점검	웹방화벽(WAF-01)	승인됨
VPN 게이트웨이 인증서 점검	VPN 게이트웨이(VPN-03)	예정

- 로컬 LLM: llama.cpp 멀티모델 풀(RTX 3090), 에이전트별 모델 배정
- RAG(장기 기억): 사내 문서를 LanceDB에 넣어 검색.근거 주입
- 헤르메스 폐쇄형 학습 루프: 실제 대화 자동 수집 → 👍 정제 → QLoRA 학습 → GGUF 배포 (전 과정 폐쇄망, 사전점검 포함)

GUIO GUIO AS 2026. 07. 16. 오후 03:29

운영중 LIVE

정

AI 팀

에이전트 AI

모니터링

대시보드

보안 KPI

AI 자산

AI-BOM

위협 인텔리전스

취약 자산관리

거버넌스

컴플라이언스

내부 리포트

승인 워크플로우

운영 가이드

코딩 기능

보안 LLM 합성

헤르메스 학습 루프

추천 LLM 가이드

AI 기역 · 학습

사용량 · 요금

시스템

로그

설정

헤르메스 학습 루프

에이전트와 나는 실제 대화가 자동으로 수집되고, 담당자가 🟡로 승인한 것만 데이터셋이 되어 로컬 GPU에서 학습(QLoRA)됩니다. 학습된 모델은 GGUF로 변환돼 에이전트에 자동 배포 — 이 모든 과정이 **폐쇄망 안에서만** 됩니다.

폐쇄망. 대화 데이터셋 학습 배포 전 과정이 이 서버(GPU 머신) 안에서만 이루어지고 외부로 나가지 않습니다.

루프 실행 중에는 GPU를 학습이 독점하므로 **채팅-문서검색(RAG)**이 일시 중지됩니다가 끝나면 자동 재개됩니다.

베이스 모델(기본 **Hermes 3 · Llama 3.1 8B**)의 학습용 원본 가중치는 첫 실행 전에 미리 받아줘야 합니다 — 폐쇄망 이전 시 **hf download NousResearch/Hermes-3-Llama-3.1-8B** 선행. 배포 모델은 **버전(-v1, -v2...)**으로 붙여 언저드 이전 버전으로 되돌릴 수 있습니다.

STEP 1수집

STEP 2정제

STEP 3학습

STEP 4배포

수집된 대화

0

금정 평가

0

학습 후보(미사용)

0

최근 배포 모델

아직 없음

사전 점검

실행 전에 준비물(Python-unsloth-gguf-llama.cpp-베이스 모델 캐시)을 확인합니다. 하나라도 빠지면 실행 도중에 실패하니, **모두 초록불**인지 먼저 확인하세요.

준비물이 빠져 있습니다 — 아래 항목을 갖춘 뒤 실행하세요.

✓ Python 실행 가능 Python 3.12.10

✓ unsloth (QLoRA 학습)

✓ gguf 패키지 (GGUF 변환)

✓ llama.cpp 변환 스크립트

✓ llama.cpp 양자화 빌드

✗ 베이스 모델 캐시 (NousResearch/Hermes-3-Llama-3.1-8B)

• hf download NousResearch/Hermes-3-Llama-3.1-8B

! 학습 데이터(🔥 대화) 현재 0건

• 대화를 더 수집하고 🔥를 남기거나, 기존 데이터셋으로 실행하세요.

다시 점검

루프 실행

원클릭 실행 시 [🔥 로그 → 데이터셋 → 학습 → GGUF 변환 → 에이전트 배포]가 순서대로 진행됩니다. 각 단계는 아래에 실시간 표시됩니다.

루프 실행 (원클릭)

데이터셋만 만들기

아직 실행 이력이 없습니다.

루프 설정

모델 대상은 신중히 바꾸세요. 베이스 모델은 HuggingFace 원본 repo id(HF transformers)이며, GGUF id가 아닙니다.

학습 베이스 모델 (HF repo)

배포 모델 접두어

배포 대상 에이전트

대화 자동 수집

NousResearch/Hermes-3-Llama-3.1-8B

hermes-sec-tuned

모델 진화 에이전트

저장

수집된 대화

좋은 답변에 🔥를 남기면 다음 학습에 채택됩니다. 🟡/삭제된 대화는 학습에서 제외됩니다. 이미 학습에 쓰인 대화는 ✓ 표시.

아직 수집된 대화가 없습니다 — 에이전트 AI 화면이나 대시보드에서 대화하면 자동으로 쌓입니다.

실행 이력

실행 이력이 없습니다.

GUIO


© 2026 GUIO Technology · GUIO AS Platform · Confidential

4.8 통합 보안 KPI 대시보드

목적: 흩어진 지표를 한곳에 + 매일 스냅샷으로 추세 → 임원 보고·방향성 결정.

실측 — 통합 스냅샷(2026-07-16):

도메인	지표
자산	전체 3 (고위험 0 / 저위험 3)
유지보수 점검	전체 6 · 지연 1 · 승인대기 1 · 승인 2 · 반려 1
CTI 자산영향	수집 5 · 자산매칭 4 · 영향 자산 3 · 긴급 3
컴플라이언스	KISA 위협 21항목 · 대응률 집계
AI 학습	배포 모델 0 (학습 실행 시 누적)



4.9 📄 임원/팀장 보고서

목적: KPI·점검 거버넌스·자산 상세를 담은 docx 보고서를 자동 생성 + 이메일 발송.
경영진 요약은 로컬 LLM이 작성, 유지보수 거버넌스 섹션(승인/반려 감사 추적) 포함.

AI 팀

● 에이전트 AI

모니터링

◆ 대시보드

📊 보안 KPI

◇ AI 자산

□ AI-BOM

△ 위협 인텔리전스

🔍 취약 자산관리

거버넌스

✓ 컴플라이언스

📄 내부 리포트

◆ 승인 워크플로우

🌟 운영 가이드

고급 기능

○ 보안 LLM 합성

📄 헤르메스 학습 루프

🗣️ AI 기억 · 학습

\$ 사용량 · 요금

시스템

📅 로그

⚙️ 설정

컴플라이언스

KISA 「AI 보안 위협 대응 매뉴얼」(2026.7) 위협 분류 × 국제 프레임워크(OWASP-NIST-MITRE) 대응 현황

전체 위협

21

대응 완료

0

부분 대응

0

미대응

21

대응률

0%

데이터 위협 (3)

▶ D01

불균형 데이터 데이터

OWASP LLM04-2025 Data and Model Poisoning NIST AML013 Data Poisoning MITRE AMLT0020 Poison Training Data

대응 근거: 메모 (선택)

미대응

▶ D02

부정확한 데이터 데이터

OWASP LLM04-2025 Data and Model Poisoning NIST AML013 Data Poisoning MITRE AMLT0019 Publish Poisoned Datasets AMLT0020 Poison Training Data

대응 근거: 메모 (선택)

미대응

▶ D03

개인정보 비식별화 미흡 데이터

OWASP LLM02-2025 Sensitive Information Disclosure

대응 근거: 메모 (선택)

미대응

모델 위협 (8)

▶ M01

학습 데이터 유출 모델 데이터

OWASP LLM02-2025 Sensitive Information Disclosure LLM10-2025 Unbounded Consumption NIST AML032 Reconstruction AML033 Membership Inference MITRE

AMLT0024-002 Extract AI Model

대응 근거: 메모 (선택)

미대응

▶ M02

백터 DB-임베딩 유출 데이터

OWASP LLM08-2025 Vector and Embedding Weaknesses NIST AML035 Prompt Extraction AML038 Data Extraction MITRE AMLT0057 LLM Data Leakage

AMLT0085-000 RAG Databases

대응 근거: 메모 (선택)

미대응

▶ M03

시스템 프롬프트 유출 프롬프트

OWASP LLM07-2025 System Prompt Leakage NIST AML038 Data Extraction MITRE AMLT0056 Extract LLM System Prompt

대응 근거: 메모 (선택)

미대응

▶ M04

모델 유출 모델

OWASP LLM10-2023 Model Theft NIST AML031 Model Extraction MITRE AMLT0024-002 Extract AI Model

대응 근거: 메모 (선택)

미대응

▶ M05

환각 모델 프롬프트

OWASP LLM09-2025 Misinformation MITRE AMLT0062 Discover LLM Hallucinations

대응 근거: 메모 (선택)

미대응

▶ M06

탈옥 프롬프트

OWASP LLM01-2025 Prompt Injection NIST AML018 Prompt Injection MITRE AMLT0054 LLM Jailbreak

대응 근거: 메모 (선택)

미대응

▶ M07

부적절한 출력 처리 모델 에이전트 도구

OWASP LLM05-2025 Improper Output Handling NIST AML027 Misaligned Outputs MITRE AMLT0067 LLM Trusted Output Components Manipulation

대응 근거: 메모 (선택)

미대응

▶ M08

모델 DoS 인프라

OWASP LLM10-2025 Unbounded Consumption NIST AML016 Availability Attacks MITRE AMLT0029 Denial of AI Service

대응 근거: 메모 (선택)

미대응

에이전트 위협 (4)

▶ A01

부적절한 도구 설계 에이전트 도구

OWASP LLM06-2025 Excessive Agency NIST AML018 Prompt Injection MITRE AMLT0053 AMLT0081 AMLT0086

대응 근거: 메모 (선택)

미대응

▶ A02

에이전트 하이재킹 프롬프트 에이전트 도구

OWASP LLM01-2025 Prompt Injection LLM06-2025 Excessive Agency NIST AML015 Indirect Prompt Injection MITRE AMLT0051-001 LLM Prompt Injection - Indirect

대응 근거: 메모 (선택)

미대응

▶ A03

에이전트 DoS 에이전트 도구 인프라

OWASP LLM10-2025 Unbounded Consumption NIST AML01 Availability Violations MITRE AMLT0029 Denial of AI Service AMLT0034 Cost Harvesting

대응 근거: 메모 (선택)

미대응

▶ A04

에이전트 메모리 오염 에이전트 도구 데이터

OWASP LLM01-2025 Prompt Injection LLM08-2025 Vector and Embedding Weaknesses NIST AML023 Backdoor Poisoning MITRE

AMLT0080-001 AI Agent Context Poisoning: Memory

대응 근거: 메모 (선택)

미대응


공급망 위협 (4)

▶ S01

데이터 포이즈닝 데이터

OWASP LLM03-2025 Supply Chain LLM04-2025 Data and Model Poisoning NIST AML05 Supply Chain Attacks MITRE AMLT0010-002 AI Supply Chain Compromise: Data

미대응




5. 한눈에 보는 상관관계 (백데이터 요약)

[샘플 CTI 위협 5건]	[내부 자산 3종]	[업무 서비스 3곳]
Qwen2.5 공급망 위협	—매칭(qwen2)—▶ 사내 보안 상담 챗봇	—▶ 임직원 보안 포털 [영향도 높음]
bge-m3 악성 패키지	—매칭(bge)—▶ 사내 보안 상담 챗봇	
KoBERT 프롬프트인젝션	—매칭(kobert)—▶ 문서 민감도 분류 AI	—▶ 문서관리 시스템 [영향도 높음]
IsolationForest 우회	—매칭(isol...)—▶ 이상행위 탐지 엔진	—▶ SOC 관제 플랫폼 [영향도 높음]
다크웹 계정 유출	—(무관, 제외)	


위협이 도착하면 **영향 자산** → **영향 서비스**까지 자동으로 이어져, 담당자는 "무엇부터"만 결정하면 됩니다.

6. 아키텍처 및 적용 기술

6.1 시스템 구성 (한눈에)



3계층 · 단일 GPU 머신 완결형:



서버 1대가 모든 상태를 단독 소유하고, 여러 데스크톱 클라이언트가 REST/WebSocket으로 접속하는 CS 구조.

서버·AI·데이터가 한 GPU 머신 안에서 완결되어 폐쇄망 배포에 적합합니다.

6.2 적용 기술 스택 (레이어별)

레이어	기술	역할
클라이언트	Electron 31 · TypeScript · esbuild	데스크톱 앱. contextBridge preload로 안전한 API 표면만 노출
	apiClient(REST) · wsClient(WebSocket)	서버 통신 · 실시간 이벤트 수신
서버(웹)	Node.js · Express 4 · TypeScript	REST API + 앱 조립. ws 로 WebSocket 브로드캐스트
	JWT(jsonwebtoken) · bcryptjs	담당자별 로그인(회전형 refresh 토큰) · 비밀번호 해시
	better-sqlite3 (SQLite, WAL)	자산·점검·승인·KPI·계정 등 전 상태 영속화
	AES-256-GCM(cryptopack)	CTI/SMTP 비밀키 암호화 저장(평문 저장 안 함)
문서/표준	@cyclonedx/cyclonedx-library	SBOM CycloneDX 1.5 생성
	(직접 생성) SPDX-2.3 JSON	SBOM SPDX 내보내기
	docx	임원/팀장 리포트(.docx) 생성
	nodemailer(SMTP)	리포트·점검 지연 알림 이메일
	simple-git	리포지토리 스캔(자산 자동 등록)
AI/데이터	llama.cpp	로컬 LLM 서빙(채팅 :8080+ 멀티모델 풀, 임베딩 :8081)
	LanceDB · Apache Arrow	장기 기억(RAG) 벡터 저장·검색
	BGE-M3	임베딩 모델(RAG 검색용)
	ModelScan (python)	AI 모델 파일 정적 취약점 스캔
	Unsloth · llama-quantize	QLoRA 파인튜닝 · GGUF 변환·양자화(자가학습)
	pypdf / OWPML	문서(PDF·HWPX·에러로그) 텍스트 추출
프로토콜	MCP(@modelcontextprotocol/sdk)	도구/에이전트 연동 표준

6.3 실시간 처리 — WebSocket 이벤트 채널(7종)

서버가 상태 변화를 모든 접속 클라이언트에 즉시 브로드캐스트합니다(풀링 없음):

collaboration:event (에이전트 협업) · llm:event (추론 실행) · asset:updated (자산 갱신) · finetune:progress · learnloop:progress (학습 진행) · hf-download:progress (모델 다운로드) · log:event (서버 로그)

6.4 핵심 데이터 흐름

- 1. **복합 지시:** 자연어 → 의도 라우팅(로컬 LLM, 규칙 풀백) → 다단계 실행 → 협업 로그 실시간 표출
- 2. **RAG:** 문서 업로드 → 텍스트 추출(python) → 청크·임베딩(BGE-M3) → LanceDB → 채팅 시 근거 주입

3. **자가학습 루프:** 대화 수집(SQLite) → 🍌 정제 → QLoRA 학습(Unsloth) → GGUF 변환(llama.cpp) → 에이전트 배포
4. **상관관계:** CTI 위협 텍스트 ↔ 자산 식별자 토큰 매칭 → 영향 자산 → 서비스 영향도 롤업

6.5 보안·배포 특성 (폐쇄망 설계)

항목	내용
데이터 주권	대화·문서·학습·자산·리포트 전 과정이 조직 내부에서 완결
외부 연결	선택적 CTI 벤더 API + 최초 모델 다운로드(폐쇄망 이전 전)뿐
GPU 조율	학습·병합 시 추론 엔진 자동 정지→재기동(단일 3090 VRAM 충돌 방지)
인증·권한	보안담당자별 로그인(JWT), admin/담당자 이분 권한
비밀정보	API키·SMTP 비밀번호 AES-256-GCM 암호화(평문 저장 안 함)
품질	서버 자동화 테스트 245개 통과 , 38개 엔진 모듈, 실기동 엔드투엔드 검증

6.6 확장·운영

- **모델 자유 교체:** 추천 LLM 가이드에서 보안·학습·RAG·경량 모델을 용도별로 다운로드, 에이전트별 배정
- **자산 자동 유입:** Nessus 취약점 업로드 · Git 리포지토리 스캔으로 자산 자동 등록
- **모델 자산 관리:** AI-BOM 5영역(모델·데이터·프롬프트·도구·인프라) + SBOM 표준 내보내기

7. 스크린샷 목록 (`screenshots/` 폴더)

아래 10장은 **실제 제품 화면**을 실측 서버 응답 데이터로 렌더링한 것입니다(1440×960, 2배 해상도).

파일	화면	보이는 실측 데이터
01-보안KPI대시보드.png	보안 KPI	자산3·점검6(지연1)·CTI영향자산3·KISA21
02-CTI위협-자산매칭.png	위협 인텔리전스	매칭 4건 → 자산 3곳(근거 토큰)
03-AI자산-서비스영향도.png	AI 자산	서비스 3곳 모두 "영향도 높음"
04-운영가이드-점검거버넌스.png	운영 가이드	점검 6건(전 상태)
05-승인워크플로우.png	승인 워크플로우	finding 검토 게이트
06-헤르메스학습루프.png	헤르메스 학습 루프	수집→정제→학습→배포
07-추천LLM가이드.png	추천 LLM 가이드	4카테고리 + 추천 배지
08-에이전트AI.png	에이전트 AI	8종 에이전트 카드
09-컴플라이언스.png	컴플라이언스	KISA 위협 21항목
10-AI-BOM-SBOM.png	AI-BOM	자산별 SBOM 생성/내보내기

재생성: 서버를 `GIJO_SERVER_PORT=4068` 로 기동 후 `node tools/gen-screenshots.mjs` (Windows Edge 사용).

실제 운영 환경 캡처가 필요하면 GIJO AS 데스크톱 앱을 로그인해 각 메뉴에서 촬영하면 됩니다.

문서 버전: v1.0.0 · 데이터 기준일: 2026-07-16 · 수치·스크린샷 모두 실제 서버 구동 결과.